

基于 PSO 算法的考虑负荷分布的车辆充电优化调度

物理与能源学院 新能源科学与工程专业
135032018055 孙士喆 指导教师：林兵

摘要：电动汽车数量的大规模进步，逐渐的导致了电动汽车的充电行为成为对导致公共电网负荷增大的最主要因素，因此本论文为了缓解电动车充电给电网所带来的影响，建立了以公共电网负荷总方差这个函数为目标函数。同时为了满足并且实现高效且正确的求解。本篇文章利用粒子群优化算法(Particle Swarm Optimization, PSO)进行对该目标函数的改良。同时考虑到电网负荷的约束，建立了静态充电模型以及在动态调度下的充电模型。在文章的结尾我们用相关的图表和数据验证粒子群优化算法(PSO)在解决电动车充电这一方面的可行性。算例最后我们分别利用不同的迭代次数(Generation)，不同的电动汽车数目以及完全不相同的电动汽车样本来检测经过粒子群优化算法(PSO)所产生电动车充电模型的泛化能力。

关键词：电动汽车；有序充电；电网负荷总方差；粒子群优化算法(PSO)；在线调度

1.引言

化石能源的逐渐匮乏，以及传统汽油车对环境的污染，引起了人类对石油可替代能源的探索。随着新能源技术的发展完善，电动汽车(Electric Vehicle, EV)充分发展起来，以电动汽车为代表新能源汽车已经开始逐步取代传统汽油车已经是必然结果^[1]。同时国家在当前新发展理念中也提出了“低碳出行，环保出行”的口号，因此相较于普通的消耗汽油，柴油的传统汽油车，排放少，消耗少的电动汽车优势便逐渐的凸显出来。再加上国家战略对于新能源汽车的大力支持以及推广，使得目前新能源汽车逐渐成为现代出行的代名词。

同样的节能减排也逐渐变成社会全体呼吁的重要问题^[2]。但由于电动车的充电过程会涉及到供电负载，会使得供电负载的负荷大幅上升，特别是当耗电量增加的时候会使得原来过多的供电负载继续增加，造成配电网的超负荷，严重影响电网的安全性和稳定性^[3-5]，因此需要对充电汽车进行合理的充电调度，以用来提高电网的安全和稳定。

计算机的发展与推广使得计算机也逐渐进入了社会的各个领域，受到各个行业领域的关注和重视。同时随着智能出行的广泛的宣传和普及，借助前沿科技和理念，包括云计算，大数据分析，互联网，物联网等。很好的提高并且促进了城市的运行效率。在此其中，电动汽车作为应用智慧出行先锋行业中的佼佼者，其利用了大量计算机领域技术，大大实现了其作为新型交通工具的方便快捷，同时也缓解了起产生的大量问题。

由于启发式计算机算法的大幅度开发,它所在的各个方面日益受到人们重视,比如经典的遗传算法, 鲸鱼算法, 模拟退火算法等, 也被逐渐应用到各个领域, 比如说在电动汽车充电领域, 目前已经有前人利用鲸鱼算法(Whale Optimization Algorithm, WOA)^[6], 鸡群算法(Chicken Swarm Optimization, CSO)^[7]等对电动汽车充电进行优化。本文所采用的粒子群优化算法(Particle Swarm Optimization, PSO), 是由美国 Eberhart 和英国 Kennedy 两个计算机领域的杰出学者们在一九九五年发明的一个, 可以通过模拟虫子、兽群、鸟群以及鱼目等群集现象的方法。该算法中鸟群使用互相协作的一个群体行为寻找美食, 鸟群中

的每一只鸟类都通过学习其自己本身觅食的经历，以及其同伴鸟群的经历来逐渐改变其寻找美食的地点。这便为粒子群优化算法的本质。其通过各个粒子之间的相互协同进行搜索计算以求得该工程问题最优解。其显著提高了搜索速度和降低了复杂程度^[8]。

电动汽车的充电调度,按照控制策略有着分散式充电与集中式充电等二类^[9]。分散式核心其实是对单辆汽车进行优化,只是在掌握全局的方法上出现了缺陷。集中式充电则是在一个区域内对电动汽车进行一个集中充电,主要强调并非单个车辆而是总体。本文通过运用粒子群算法对同一个范围内的电动汽车实施充电优化调整,以"削峰填谷"为目的通过优化各电动汽车的开始充电时间,以电动汽车到来时间和离去时间为约束,以单时段内的可充电电动汽车最大数为约束,从而得到电动汽车充满时间中对供电负荷影响最小的最优的充电时间。

本文主要借鉴了周美玲和陈准丽的论文内在约束和公式进行关于电动车充电数据的限制^[10],同时也借鉴了黄小庆、陈颀等文章中的电动车返回时刻以及充电时刻等正态分布公式进行限制^[11]。同时借鉴了李红章等的文章中的粒子群算法在充电电动车上的调用进行程序的修改与改进^[12]。最后利用粒子群算法对优化电动汽车充电方式进行求解。

2 电动汽车有序充电

2.1 电动车充电规律

关于电动汽车(EV)的充电行为,现在社会上比较标准的充电方法是使用类似于充电桩装置对电动汽车进行集体充电。因为电动汽车的输出功率要超过普通的电力运输工具,比如电力自行车等等,因此电动汽车的充电行为必须在专门的设施,专门的地点,如电动汽车充电站等设施内进行自体的充电行为。由这一点我们可以看出,电动汽车的充电并非随机随地,而是有序且有迹可循的。因此我们

对于电动充电汽车充电行为,看似无序,但是在某些情况下会满足特殊的正态分布特征。本文通过借用其他学者论文中提出的结论公式从而得到近似拟合出电动车的充电规律^[13]。

电动汽车到达充电桩的返回时刻 x_s , 其满足正态分布, 概率密度 f_s 公式为:

$$f_s(x_s) = \begin{cases} \frac{1}{\sqrt{2\pi}\sigma_s} \exp\left[-\frac{(x_s + 24 - \mu_s)^2}{2\sigma_s^2}\right] & (0 < x_s \leq \mu_s - 12) \\ \frac{1}{\sqrt{2\pi}\sigma_s} \exp\left[-\frac{(x_s - \mu_s)^2}{2\sigma_s^2}\right] & (\mu_s - 12 < x_s \leq 24) \end{cases} \quad (1)$$

其中 μ_s 为概率密度函数的期望值, $\mu_s = 17.47$; 其中 σ_s 是代表概率密度的标准差, $\sigma_s = 3.41$

出行时间 x_e 为电动汽车离开充电设施的时刻, 满足时间正态分布, 其概率密度 f_e 的函数方程为:

$$f_e(x_e) = \begin{cases} \frac{1}{\sqrt{2\pi}\sigma_e} \exp\left[-\frac{(x_e - \mu_e)^2}{2\sigma_e^2}\right] & (0 < x_e \leq \mu_e + 12) \\ \frac{1}{\sqrt{2\pi}\sigma_e} \exp\left[-\frac{(x_e - 24 - \mu_e)^2}{2\sigma_e^2}\right] & (\mu_e + 12 < x_e \leq 24) \end{cases} \quad (2)$$

其中 μ_e 为概率密度函数的期望值, $\mu_e = 8.92$, σ_e 为概率密度函数的标准差, $\sigma_e = 3.24$ 。

通过(1)(2)两个概率密度分布，我们可以很好的得出电动汽车到达充电站的时间一起离开充电站的时间。并且可以由此计算出电动汽车在充电站停留时间。

电动汽车的日行里程 x_m 服从正态对数分布，其概率密度函数 f_m 为：

$$f_m(x_m) = \frac{1}{\sqrt{2\pi}\sigma_m x_m} \exp\left[-\frac{(\ln x_m - \mu_m)^2}{2\sigma_m^2}\right] \quad (3)$$

其中 μ_m 为概率密度函数变量 x_m 和对数 $\ln x_m$ 的均等数，其 μ_m 经过合适调整得到为 $\mu_m=2.8$ ， σ_m 为概率密度函数变量 x_m 和对数 $\ln x_m$ 的标准差，其数值 σ_m 为 $\sigma_m=1.14$ 。

我们可以很好的通过日行里程转化成电动汽车的耗电量，所以我们可以很好得出电动汽车刚刚到达充电设施的电量为：

$$E_D(i) = E_s - \varphi d(i) \quad \forall i \in I_{sum} = \{1, 2, \dots, i\} \quad (4)$$

$$\Phi = E_{his} / D_{his} \quad (5)$$

其中 I_{sum} 为待充电电动车总数， $E_D(i)$ 为第 i 辆车剩余电量， E_s 为电动汽车所能拥有的最大电量。其中的 Φ 为电动汽车的标准耗电系数， $d(i)$ 为该电动汽车在调度周期所行驶的里程， E_{his} 为单量电动汽车的耗电量， D_{his} 为单辆电动汽车行驶里程数值。

2.2 电动车充电约束条件

本文提出多个约束条件来对模型进行约束，以保证模型尽可能符合现实情况。

1) 电动车 d_i 在一个时间段 ΔT 中的充电量 x_{it} 满足

$$x_{it} = \Delta T \cdot \frac{\mu}{60} \cdot \varepsilon \quad (6)$$

其中 μ 为电动汽车的所能承受的最高充电功率，而 ε 为电动汽车的充电效能。

2) 我们要求电动车 d_i 的充电量不大于它的需求 N_i ，故因此满足约束条件

$$\sum_{t \in \Delta T} d_i \leq N_i \quad (7)$$

我们需要要求所有电动汽车的开始充电时间 st_i ，必须满足大于等于电动汽车到达充电站的时间 t_i

$$st_i \geq t_i, \quad \forall d_i \quad (8)$$

我们要求在时间 t 中可同时充电的电动汽车数量 Nd 应小于最大可充电车数量 N

$$\text{Max}(Nd) \leq N \quad (9)$$

我们主要通过限制最大充电车数量来减少充电车对电网的负担，从而实现电动汽车的优化调度。

2.3 电动汽车目标函数

由于本文着重关心于电动汽车在电网中的实际负载问题，所以对该模型的目标函数要求是将电网的实际负载总方差波动最小化，在波动值很小的情形下表示实际负荷并没有偏离平均负荷，且可以使优化作用更加明显。因此，可以通过优化的电动汽车调度充电计划，来降低负荷的方差波动。

$$\min f_2 \frac{\sum_{t=1}^T (L_s(t) - L_{av})^2}{T} \quad \forall t \in T_{sum} \quad (10)$$

$$L_s(t) - L_r(t) = L_c(t) \quad \forall t \in T_{sum} \quad (11)$$

$$L_{av} = \frac{\sum_{t=1}^T L_s(t)}{T} \quad \forall t \in T_{sum} \quad (12)$$

其中 $L_s(t)$ 为在时段 t 时候加入电动汽车的总负荷, 其中 $L_r(t)$ 为在时段 t 中的基础负荷, $L_c(t)$ 为电动汽车的充电负荷。 L_{av} 为在调度时间内的平均负荷。

2.4 电动汽车在线调度模型

因为电动汽车的充电模型, 并非是简单的静态模型, 因为时间是逐步推进的, 所以我们根本无法根据静态的数据很好的推断出电动汽车(EV)的到达充电桩时间(x_s)和离开充电桩时间(x_e), 所以我们可以把这个模型看成由无数个静态模型($P_1, P_2, P_3, P_4, \dots, P_i$)组成的在线调度模型。在每个静态模型中, 存在着已经开始充电但是还未能充满的($D_1, D_2, D_3, \dots, D_{j-1}, D_j$)和已充电车($D_{j+1}, D_{j+2}, D_{j+3}, \dots, D_{i-1}, D_i$), 未充满的电动车中对所有的车有 $1 \leq n \leq j$, 且满足车辆的充电完成时间 $C_i \leq T_k$ 和 $st_i \leq T_k$ 。

但是因为我们无法生成无数个静态模型来推导动态模型问题, 故我们人为近似生成每个 $T_k - T_{k-1} = 600s$ 的 144 个静态模型, 并且采用滑块窗口方案^[14]。如图 1。




图 1 控制时段示意图

Fig. 1 Schematic diagram of control period

在每个 T_k 内, 通过控制器检测在 $[T_{k-1}, T_k]$ 内的到达车辆来创建 P_k 并检测该时段内电动汽车的可充电信息, 再为之后的调整定义出新的滑行视窗。新的滑行视窗将被界定为当前符合最大数量 N 约束的新电动汽车到达时间与正在充电的电动汽车的最新可用充电时间之间的时间之后, 控制器通过得出新的滑行视窗获得了更新的解决对策 S_k , 而 S_k 会替换之前的解决方案 S_{k-1} 。若车辆未能在期望离开时间之前完成电量补充, 则将按照生成满足约束的起始电量补充日期继续进行充电直至电量为满。在 T_k 内, 只要车辆还没有充电, 可以在不同的 P 中分配不同的 x 一旦该车辆正在充电, 该车辆的 x 就不能再改动。

3. 粒子群优化算法

3.1 基本思想

算法(Algorithm)是一种对问题解答方案的具有完整性和准确性的描述。而算法优化(Algorithm Optimiza)是对这种解答方案的一种更为简便, 减少复杂程度的改良。比如减少某算法的时间复杂程度, 减少某算法的空间复杂程度。增加某算法的正确性能, 增加某算法在运行中的健壮性。同时还可以提高

算法的泛用优化能力。

粒子群优化算法(Particle Swarm Optimization,PSO)，该算法是一种有着十分高效性能的集群算法，作者该算法的灵感来源于各类动物的捕食这一基本行为，鸟群通过个体之间的信息相互传递来寻找全局最优点^[15]。粒子群算法在因为其参数较少，原理简单等优越特点，近些年来一直被广泛的进行应用。

该算法假定了三种限制：

第一：该算法中的每个种群粒子的体积以及质量全部忽略不计。所有的粒子只含有两个属性，速度属性和位置属性。

第二：每个种群粒子在得知自己所在的维度空间的运动行为后，通过改变其速度属性进而改变其方向属性从而最终改变该粒子空间内所处地点。

第三：粒子存在记忆能力，该粒子将记忆空间中的最优粒子行为所得到的最少的数值解进而保存最优解。

所有的动物都被确认为不具有质量属性和体积属性的一个微粒，同时该特性也将出现在和拓展到 N 维空间，粒子 I 在 N 维空间的位置表示为矢量 $x_i=(x_1,x_2,\cdots x_n)$ ，飞行速度表示为矢量 $V=(v_1,v_2,\cdots v_n)$

任何粒子都有一种由目标函数所确定的适应价值(fitness value)，而且已知自身到目前为止出现的最好方位($pbest$)和现在的方位 x_i 。这个可以看做是微粒自己的飞行经验，除此之外，各个微粒还了解到目前为止在各个种群中各个微粒出现的最佳位置($gbest$)($gbest$ 是 $pbest$ 中的最好值)。这个可以看作是微粒同伴的经验，因为粒子就是利用自己的经验和同伴中最好的经验，来选择下一步的运动。

3.2 更新原则

PSO 首先初始化为一群随机粒子，作为初始状态。然后再进行迭代找到最佳解。在每一次的迭代中，粒子可以透过跟踪两个“极值”($pbest$, $gbest$)来更新自己。在找到这两个最优值后，粒子可以使用下面的公式来更新自己的速度和位置。

$$v_i = v_i + c_1 \cdot rand() \cdot (pbest_i - x_i) + c_2 \cdot rand() \cdot (gbest_2 - x_2) \quad (13)$$

$$x_i = x_i + v_i \quad (14)$$

在公式中， $i=1,2,3,\dots N$ ，其为粒子总数， v_i 为粒子的速度， $rand()$ 为一个介于(0,1)的随机数， x_i 为粒子的当前位置， c_1 和 c_2 为 PSO 的学习因子，在一般情形下， $c_1=c_2$ ， v_i 的最大值为 V_{\max} ，但假如 v_i 大于 V_{\max} 的话，令 $v_i=V_{\max}$ 。进而以上两个公式形成了 PSO 的基本形式。

3.3 公式改进

由于最基础的 PSO 公式存在一些优化不充分等问题，故之后有新的学者对公式(13)进行了参数上的改进，引入了惯性权重因子 ω ，进而形成了公式：

$$v_i = \omega \cdot v_i + c_1 \cdot rand() \cdot (pbest_i - x_i) + c_2 \cdot rand() \cdot (gbest_2 - x_2) \quad (15)$$

其中 ω 的值不是负数，称之为惯性因子。其中公式(14)(15)合并称为标准 PSO 算法。

3.4 算法流程

Step1:通过算法初始化一群数量为 m 粒子，并给出每个粒子随机位置和随机速度；

Step2:评价每个微粒的适应程度;

Step3:针对各个微粒, 将其计算得出的相应值与其经过的最佳的位置 $pbest$ 进行比较, 如果较为出色, 我们将该数据作为当前 $pbest$;

Step4:对各个微粒所得到的适应值与得到的最佳位置的 $gbest$ 进行比较, 如果该适应值出色, 便将其作为 $gbest$;

Step5:根据上文(14)(15)式进行数据的更新, 调整微粒最好位置和速度;

Step6:该流程如果未达到结束条件则转到 Step2 继续循环;

该算法的终止条件通常选为最高迭代次数 G_k 或者是微粒搜索到的最优位置的最小阈值。

其算法框图如下:

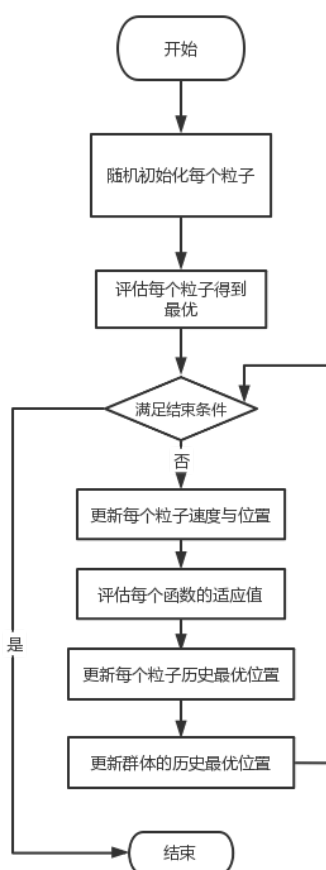


图 2 PSO 算法框图

Fig.2 Particle swarm optimization algorithm frame

4.充电模型流程求解图

Step1:我们通过已知公式自动随机生成电动车数据, 其包含了电动车到达充电站的时间以及离开充电站的时间以及充电电量。

Step2:我们以电动车充电限制条(5)(6)(7)(8)和电动车的在线调度模型作为限制, 以负荷总方差函数

为目标函数编写出的充电函数 fit_fun 。

Step3:我们规定粒子群总数 pop ; 迭代次数 $generation$; PSO 的学习因子 c_1 和 c_2 ; 以及惯性权重因子 ω ; 同时我们初始化 $pbest$ 和 $gbest$, 按照限制条件随机生成电动车的充电开始时间。并将随机数据代入 PSO 中。

Step4:我们将通过 PSO 得到的优化后的数据, 通过 fit_fun 进行运算得到 $pbest$ 值, 如果其值劣于 $gbest$, 则继续保留 $gbest$ 。若其值优于 $gbest$, 则令 $gbest=pbest$ 。

Step5:判断是否到达迭代次数 $generation$ 。

Step6.1:若到达迭代次数, 返回 $gbest$ 以及所生成的数据集。

Step6.2:若未到达迭代次数, 重复 Step4, Step5。

如图 3

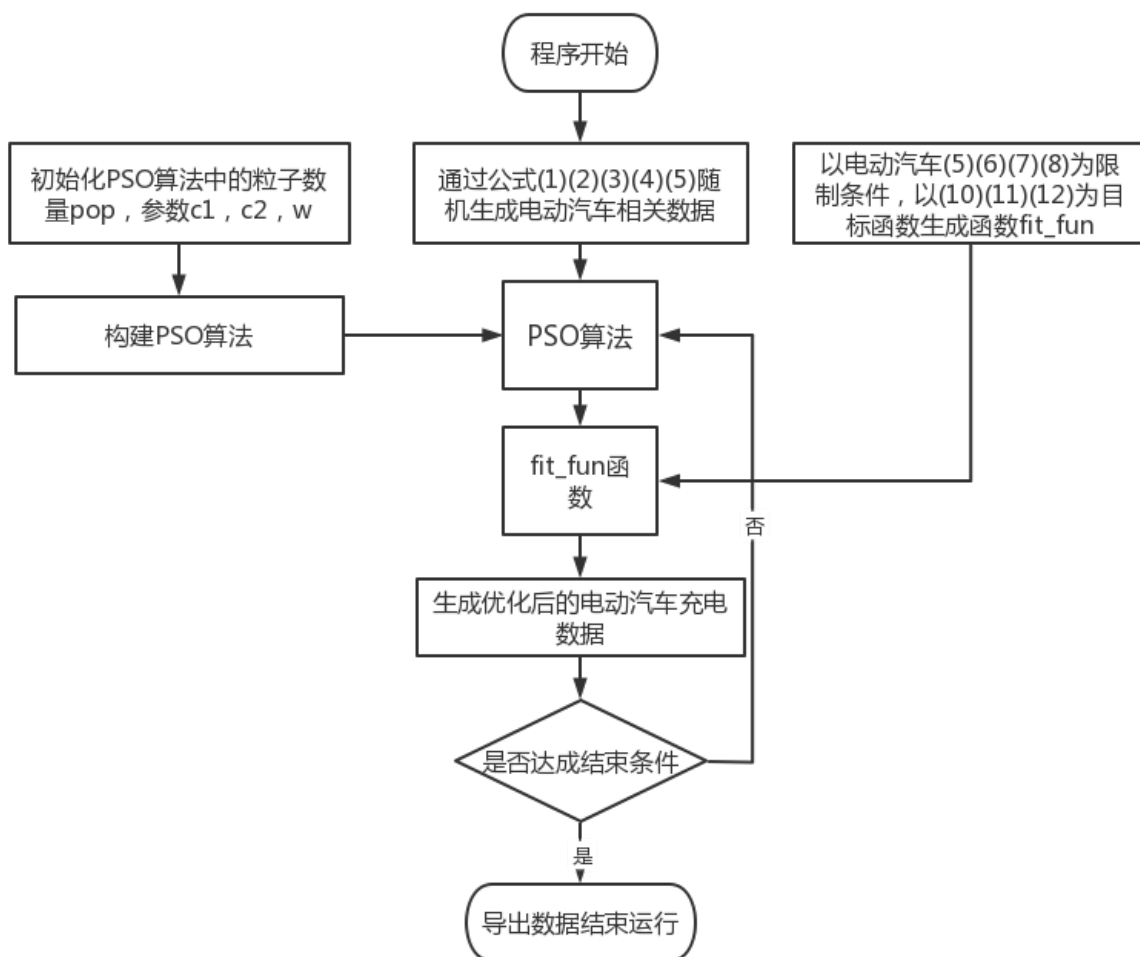


图 3 电动汽车充电模型框图

Fig.3 Electric vehicle charging frame

5.仿真验证

5.1 测试函数

本文为了验证 PSO 函数的实用性价值，我们利用了 Hölder table 测试函数来对本算法进行测试，两种函数的信息表如下：

其中我们生成了 Hölder table 函数图形，发现该算法所得到的全局最低点基本符合图像中的全局最低点。

我们通过该图像和数据可以得到该算法有着很好的收敛性和求解问题的能力。故我们可以利用该算法来解决 EV 充电的负荷问题。

5.2 充电仿真

本文以居民小区的家庭配电网路作为模型样本，并应用上文给出的 2009 年美国家庭出行调查 (National Household Travel Survey, NHTS) 的研究结论。汽车到达充电站的时间，离开充电站的时间，以及其耗电量的正态分布函数见上文公式。

我们从正态分布函数生成的电动汽车内选取 100 量电动汽车的数据作为我们的样本集。其中我们依据现实数据设置电动汽车的行驶里程数最大不超过 220km，最小不低于 30km。其中每公里单位耗电量为 0.16kw·h/km，其中充电功率我们设置为 20kw。

对于我们 PSO 内部的参数设置，我们设定该算法存在 500 个粒子，并且该算法的迭代次数为 300 次。其中 PSO 学习因子 $c_1 = c_2 = 0.1$ ；惯性因子 $\omega = 1$ ；PSO 内部参数 $rand()$ 设置为 1。

以下是选取得到的部分数据展示图：

表 1 电动汽车部分数据展示图

List1. Part of the electric vehicle data figure

EV 编号	EV 出行时间/h	EV 离开时间/h	EV 所需充电时长
1	14.8	23.5	0.5
17	7.1	15.5	0.3
25	5.6	13.8	0.5
47	9.1	17.5	0.6
60	12.3	21	0.6
77	9.8	18.1	0.5

5.3 仿真结果

首先我们的程序重点目标在于如何使得负荷方差总波动最小，其次我们假设了所有充电的电动汽车都决定服从我们的充电调度。按照以上限制我们绘制出在 *generation* 为 200 时候的负荷方差总波动折线图以及其优化后的最小负荷方差总波动数据。

并且，我们对算法的性能进行了实验确认，我们将迭代次数 *generation* 分为 50，100，200，300 次后进行图像绘制。




图 4 迭代次数为 50 次时得到的电网负荷总方差折线图




图 5 迭代次数为 100 次时得到的电网负荷总方差折线图




图 6 迭代次数为 200 次时得到的电网负荷总方差折线图




图 7 迭代次数为 300 次时得到的电网负荷总方差折线图

表 2 不同迭代次数下的电网负荷总方差数值

List.2 Values of the total variance of the grid load for different numbers of iterations

迭代次数	电网负荷总方差
50	0.642746913580245
100	0.614969135802467
200	0.5871913580246894
300	0.5871913580246894

由图 4-7 和表 2 我们可以很好的发现，随着迭代次数的增加，随之而来的负荷方差总波动数据也随之减小，进而我们可以得出如果迭代次数足够且合适，我们可以找到符合负荷方差总波动最小的最优点。

为了测试我们的得到的数据是否已经进行优化，我们假定所有充电汽车都进行无序调度，按照随机时间开始进行充电。我们将经过 PSO 算法优化后的数据与完全随机的充电数据进行负荷方差总波动对比，结果如下图


表 3 PSO 算法优化后的电网负荷总方差与完全随机安排的
电网负荷总方差之比

List.3 The comparison of the algorithm optimization and random arrange in Values of the total variance of the
grid load

PSO 算法优化充电	完全随机充电
0.5871913580246894	1.045524691358022

从图 9 中的两个数据可以很好地得知，该算法所进行的充电调度，很好的实现了减少负荷方差总波动，减轻了电网压力，减少了 EV 充电所带来的电网电压压力。

我们为了验证该模型的泛化能力是否优秀，我们生成了多组到达充电站时间和离开充电站时间不同的 100 辆汽车数据，如图。我们将其都进行 PSO 充电调度优化得到以下结果。



迭代次数	负荷方差
200	0.6427469135802449

图 9 样本不同的 100 辆车的电网负荷总方差

Fig.9 The 100 different samples in values of the total variance of the grid load

由图 6 和图 9 的对比我们可以得出，即使变换了样本，该模型仍然能很好的优化电动汽车充电时间，进而减小电网负荷总方差数值。

我们设立了另外两个对照组，其中一个对照组包含 50 辆车，另一个对照组包含 100 辆汽车，三个实验组其他限制条件和数据都相同。将他们通过进行 PSO 有序充电后所生成的数据图，与他们无序充电后生成的图像进行比较。




图 11 汽车总数为 50 时的电网负荷总方差




图 12 汽车总数为 100 时的电网负荷总方差

根据图 11 和图 12 我们发现,该模型在解决不同情况下的电动汽车充电问题时,都表现出不错的优化调节能力。进而我们可以确信,该模型的泛化能力较强,有着能解决一般问题的能力。

5.4 结果分析

我们通过优化充电调度后,可以很好的发现其大大减少了电网负荷方差总波动。我们通过验证 PSO 算法的效率,确定了该算法在解决问题时候的可行性,确定该算法可以很好的解决我们本文提出的关于配电网中电动汽车充电优化调度问题。我们由限制条件得出的模型的图像数据来看可以很好的得出 PSO 优化的后的电动车充电调度产生的电网负荷小于电动车充电随机调度的电网负荷。即使我们改变相关参数,并且增大减少样本数量,该模型的泛化程度依然十分优越和出色。并且 PSO 优化后的模型随着循环次数 generation 的增大,其模型的精准程度也越高。可以很好的接近全局最小点,也就是使得负荷方差总波动数据最小的位置。

6.结语

本篇文章为了解决配电网中的车辆优化调度问题,我们选用了 PSO 算法建立起了以电网负荷方差总波动为目标函数的车辆优化调度模型。在该优化模型中,我们的调度策略可以通过算法优化调节服从调度分配的电动车的充电开始时间。该模型的算例所得到的仿真结果表明,该算法所形成的有序充电策略,能够很好的使得配电网中的负荷方差总波动维持在一个相对较小的数值,使得其能很好的实现削峰填谷,且随着该算法迭代次数的增大,该模型的精确程度会越来越高。同时经过我们对模型的测试可以很好地看出,该模型有着很好的泛用性,其在充电电动汽车数据到达充电站时间不同,离开充电站时间不同的情形下,仍然能很好的实现令负荷方差总波动维持一个相对较小的数据的要求。

7.感谢

感谢协助我完成该论文的指导老师林兵教授,同时也感谢在关键代码部分替我答疑解惑的前辈。最后感谢各位老师同学对我论文的大力支持。

参考文献

- [1] 王镜宇,邢锐. 中国新能源汽车能否实现“弯道超车”[N]. 中国经济时报, 2018-11-07.
- [2] 段小宇,胡泽春,崔岩,等. 长时间尺度下的电动汽车有序充放电调度[J]. 电网技术, 2018, 42(12): 4037-4044.
- [3] Hübner M, Zhao L, Mirbach T, et al. Impact of large-scale electric vehicle application on the power of supply[C]//Electrical Power & Energy Conference(EPEC), Montreal, 2009: 1-6.
- [4] Fernandez L P, San Roman T G, Cossent R, et al. Assessment of the impact of plug-in electric vehicles on distribution network[J]. IEEE Transaction on Power Systems, 2011, 26(1): 206-213.
- [5] 胡泽春,宋永华,徐智威,等. 电动汽车接入电网的影响与利用[J]. 中国电机工程学报, 2012, 32(4): 1-10.
Hu Zechun, Song Yonghua, Xu Zhiwei, et al. Impact and utilization of electric vehicles integration into power systems[J]. Proceedings of the CSEE, 2012, 32(4): 1-10.
- [6] 张公凯,陈才学,郑拓,等. 改进鲸鱼算法在电动汽车有序充电中的应用[A]. 计算机工程与应用,

- 2021, 57(4), 272-278.
- Zhang Gongkai, Chen Caixue, Zheng Tuo, et al. Application of Improved Whale Optimization Algorithm in Ordered Charging of Electric Vehicle[J]. Computer Engineering and Applications, 2021, 57(4), 272-278.
- [7] 吴甲武, 邱晓燕, 潘胤吉, 等. 基于改进鸡群算法的电动车有序充电策略研究[J]. 电测与仪表, 2019, 56(9), 97-103.
- Wu Jiawu, Qiu Xiaoyan, Pan Yinji, et al. Research on orderly charging strategy of electric vehicle based on improved chicken swarm optimization[J]. Electrical Measurement & Instrumentation, 2019, 56(9), 97-103.
- [8] James Kennedy, Russel Eberhart. Particle Swarm Optimization[J]. IEEE, 1995, 1942-1948.
- [9] SHAO s, PIPATTANASOMPORN M, RANHAS S. Demand response as a load shaping tool in an intelligent grid with electric vehicles[J]. IEEE Transactions on Smart Grid, 2011, 2(4), 624-631.
- [10] 周美玲, 陈淮莉. 基于负荷平衡的电动汽车模糊多目标充电调度算法[J]. ISSN, 2021, 41(4): 1192-1198.
- Zhou Meiling, Chen Huaili. Fuzzy multi-objective charging scheduling algorithm for electric vehicle based on load balance[J]. ISSN, 2021, 41(4): 1192-1198.
- [11] 黄小庆, 陈颀, 谢啟波, 等. 用户充电选择对电网充电调度的影响[J]. 电工技术学报, 2018, 7, 33(13): 3002-3011.
- Huang Xiaoqing, Chen Jie, Xie Qibo, et al. The Influence of User's Charging Selection on Charging Schedule of Power Grid[J]. Transaction Of China Electrotechnical Society, 2018, 7, 33(13): 3002-3011.
- [12] 李红章. 基于改进粒子群算法的电动汽车充电调度优化研究[D]. 陕西: 长安大学, 2021.
- Researcher on Electric Vehicle Charging Scheduling Based on Improved Particle Swarm Algorithms[D]. Shan Xi: Chang An University, 2021.
- [13] 田立宁, 史双龙, 贾卓. 电动汽车充电功率需求的统计学建模方法[J]. 电网技术, 2010, 34(11), 126-130.
- Tian Lining, Shi Shuanglong, Jia Zhuo. A statistical model for charging power demand of electric vehicles[J]. Power System Technology, 2010, 34(11), 126-130.
- [14] KI Y, Kim B I, KO Y M, et al. Charging scheduling problem of an M-to-N electric vehicle charger[J]. Applied Mathematical Modelling, 2018, 64: 603-614.
- [15] Zhan Z H, Zhang J, Li Y, Chung H S H. Adaptive particle swarm optimization. IEEE Transactions on Systems, Man, and Cybernetics-Part B, 2009, 39(6): 1362-1381

Optimal scheduling of vehicles charging considering load distribution basing on PSO algorithm

College of Physics and Energy, New Energy Science and Engineering

135032018055 Sun Shizhe Adviser: Lin Bing

Abstract: The development in the large mount of the electric vehicles has piecemeal resulted in the charging code of conduct in electric vehicles. And the electric vehicles problem has become the most crucial ways in increasing the load on the public supply system. Therefore this paper establishes the total variance of the load on the public grid as a function of the objective function in order to mitigate the impact of electric vehicle charging on the grid. To meet and achieve an efficient and correct solution. This paper uses Particle Swarm Optimization (PSO) to improve this objective function. A static charging model and a charging model under dynamic dispatch are also developed, taking into account the grid load constraints. At the end of the paper we verify the feasibility of the Particle Swarm Optimization (PSO) algorithm for EV charging using relevant graphs and data. The example concludes by testing the generalization ability of the PSO generated EV charging model using different iterations (generations), different numbers of EVs and a completely different sample of EVs.

Keywords: Electric vehicles(EVs); orderly charging; total variance of grid load; particle swarm optimization algorithm(PSO); online scheduling